

Лабораторная работа 11. PySpark

1. Порядок выполнения работы

1. Решите задачу классификации цветков ирисов с использованием PySpark
2. Решите задачу классификации пассажиров титаника с использованием PySpark [<https://www.kaggle.com/c/titanic>]

При выполнении не разрешается:

- Использовать библиотеку pandas
- Использовать библиотеку sklearn

Полезные импорты:

- `from pyspark.ml.classification import LogisticRegression`
- `from pyspark.ml.evaluation import MulticlassClassificationEvaluator` - для оценки качества работы алгоритма
- `from pyspark.ml.feature import StringIndexer, OneHotEncoder, VectorAssembler` - для предобработки признаков

2. Содержание отчета

В отчете следует указать:

- Введение
- Программно-аппаратные средства, используемые при выполнении работы.
- Основную часть (описание самой работы), выполненную согласно требованиям к результатам выполнения лабораторного практикума.
- Заключение (выводы).
- Список используемой литературы.

3. Литература

1. Алгоритмы классификации в pyspark / <https://spark.apache.org/docs/latest/ml-classification-regression.html#classification>
2. Пример решения задачи классификации на pyspark / <https://towardsdatascience.com/machine-learning-with-pyspark-and-mlib-solving-a-binary-classification-problem-96396065d2aa>